# 实验二: Linux环境下C语言编程

#### 郑海刚

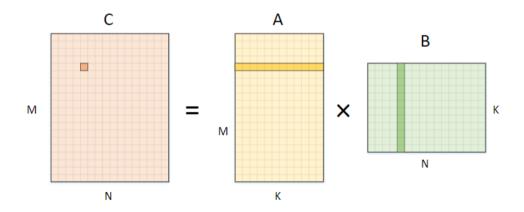


### 本讲概述

- 主要内容
  - naive gemm
  - ■可执行文件生成
  - blas & openblas
  - 时间测量

#### 通用矩阵乘法: GEMM

- GEMM (General matrix multiply)
  - 一个被广泛使用的基础算法,例如深度学习中的卷积操作
  - 双精度浮点简写为DGEMM, 单精度浮点简写SGEMM



### naive dgemm (朴素版本)

- lab2/dgemm\_naive.c
- gcc dgemm\_naive.c编译
- ./a.out执行
  - 只输入a.out是没法执行的

• gcc dgemm\_naive.c && ./a.out 编译后直接执行

可执行文件生成:编译、汇编、链接

- gcc xx.c 生成a.out可执行文件, 经历了什么过程?
  - 预处理: gcc –E xx.c -o xx.i 生成.i文件
  - 编译: gcc -S xx.i -o xx.s生成汇编代码文件
  - 汇编: gcc -c xx.s -o xx.o生成可重定位目标文件
  - 链接: gcc xx.o xx.o 合并生成最后的可执行文件
    - 静态链接
    - 动态链接

链接: lab2/link

• 将多个可重定位对象文件拼接在一起

■ 多个C代码项目, 存在互相调用

• 只有一个文件是否要链接?

- 也需要,调用库函数如printf需 链接标准库
  - 即使只有main函数,也需要链接 到运行时库

lab2/link »cat main.c #include<stdio.h> int sum(int n);

printf("%d\n", sum(100)); lab2/link »cat sum.c int sum(int n){ int sum=0;

int main(){

\$ lab2/link »ls main.c sum.c

for(int i=1; i<=n; i++){ sum += i; return sum;

lab2/link »gcc -c main.c sum.c lab2/link »ls main.c main.o sum.c sum.o lab2/link »gcc main.o sum.o lab2/link »ls

a.out main.c main.o sum.c

### 编译、链接

- 难点是编译、链接
  - 预处理主要复制粘贴、去除注释, 相对比较简单
  - 汇编: 汇编代码到机器码, 基本是一对一映射
- 为什么要了解这样的过程?
  - 作为计算机专业的同学需要探知原理
  - 大型项目的构建需要,知道编译链接的过程才知道怎么写makefile
  - 编译出错的时候, 更容易解决问题

#### BLAS (基础线性代数程序集)

- BLAS(Basic Linear Algebra Subprograms)
  - 是一套标准,包含了低级别的线性代数操作
    - level1: 向量操作
    - level2: 矩阵向量操作
    - level3: 矩阵矩阵操作
  - <a href="http://www.netlib.org/blas/">http://www.netlib.org/blas/</a> 提供了API定义同时提供了参考实现BLAS
  - 有多种实现: GotoBLAS、cuBLAS、Intel MKL、

### **OpenBlas**介绍

- 基于GotoBLAS2 1.13 BSD version实现的高性能BLAS库
- OpenBlas怎么用
  - RTFM: <a href="https://github.com/xianyi/OpenBLAS/wiki/Document">https://github.com/xianyi/OpenBLAS/wiki/Document</a>
  - <u>源码编译安装</u>: 可以安装最新的版本, 只需make一下
  - <u>预编译</u>: sudo apt install libopenblas-dev
  - 预编译默认装在系统路径
    - /usr/lib/x86\_64-linux-gnu/
    - /usr/include/x86\_64-linux-gnu/

### <u>User Manual</u>: OpenBlas Code examples (1)

- lab2/test cblas dgemm.c:
  - 编译: gcc -o test\_cblas\_open test\_cblas\_dgemm.c -lopenblas

## cblas\_dgemm()接口参数

- MKL接口说明: C := alpha\*op(A)\*op(B) + beta\*C
- 参数说明
  - layout: 行主序或列主序
  - transa, transb: 矩阵A、B是否转置或共轭转置
  - m, n, k: 实际计算的矩阵的行列数
  - alpha, beta: 系数
  - a, b, c: 指向原始矩阵A、B、C的指针, 一维数组
  - Ida, Idb, Idc: a,b,c指向的矩阵的 leading dimension

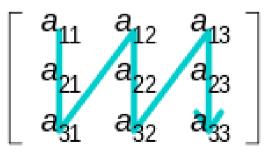
### 行主序、列主序(也叫行优先、列优先)

- Row- and column-major order Wikipedia
  - 多维数组在线性的存储空间中的存储方式
  - 行主序: 行的连续元素相邻
  - 列主序: 列的连续元素相邻
- lab2/row\_major.c
  - 打印二维数组的元素地址
  - C语言二维数组是连续存储,行主序
  - Fortran是列主序
- CPU缓存,访问相邻地址的数据会更快

### Row-major order

$$\begin{bmatrix} a_{11} & a_{12} & a_{13} \\ a_{21} & a_{22} & a_{23} \\ a_{31} & a_{32} & a_{33} \end{bmatrix}$$

### Column-major order

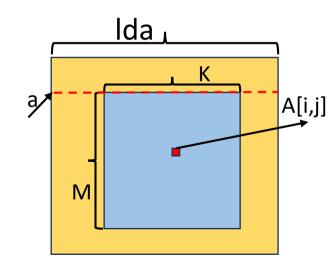


#### Ida、Idb、Idc

- leading dimension: 如果是行主序,就是每行的元素个数;列主序是每 列的元素个数。
- 有了m,n,k三个参数为什么还需要lda,ldb,ldc?
  - 大矩阵分块计算时只用到一部分数据
  - 行主序无转置的情况: Ida > = k

1da Specifies the leading dimension of a as declared in the calling (sub)program.

|                        | transa=CblasNoTrans             | transa=CblasTrans or transa=CblasConjTrans |
|------------------------|---------------------------------|--|
| Layout = CblasColMajor | 1da must be at least max(1, m). | 1da must be at least max (1, k)            |
| Layout = CblasRowMajor | 1da must be at least max(1, k)  | 1da must be at least max (1, m).           |



### OpenBlas Code examples (2)

- lab2/time\_dgemm.c
  - 编译: gcc -o time\_dgemm time\_dgemm.c -lopenblas
  - 运行: ./time\_dgemm 1024
  - 除了printf输出,还生成了timeDGEMM.txt文件
  - 数组空间由malloc分配,固定初始化或随机初始化
  - 时间测量: gettimeofday
  - <u>gflops</u>: 浮点操作次数 (4\*m\*n\*k) 除以时间

#### 时间测量: time命令

• time Is

```
:~/hpc/tmp$ time ls

real 0m0.002s
user 0m0.001s
sys 0m0.001s
```

What do 'real', 'user' and 'sys' mean in the output of time(1)?

■ real: 时钟时间(墙上时间), 有些shell下是total

■ user: 用户cpu时间

■ sys: 系统cpu时间

■ cpu时间 = user+sys

■ (user + sys)/real就是程序的cpu利用率,要考虑多个CPU的情况

#### CPU时间和时钟时间

- 无限循环: lab2/while.c
  - 编译: gcc while.c
  - 运行: time ./a.out , 使用ctrl+c终止
  - real time > cpu time (user+sys)
    - sleep把进程切换出去
    - sleep的时间不计入cpu但计入real
  - 无限循环cpu还能执行其他程序
    - 时钟中断, 操作系统会把进程切换出去

```
#include<stdio.h>
     #include <unistd.h>
     int main(){
         int a = 0:
         while(1){
             a++;
             if( (a%100000000) == 0){
10
                 sleep(1);
11
                 printf("a = %d\n", a);
12
13
```

#### 时间测量: 代码中使用测量函数

- time命令只能粗略测整个程序的运行时间,精度是ms级
- gettimeofday函数,返回时间戳,精度是us级
  - <u>Unix time</u> 时间戳, <u>https://www.unixtimestamp.com/</u>在线转换
  - man gettimeofday
    - struct timeval \*tv

```
struct timeval {
   time_t tv_sec; /* seconds */
   suseconds_t tv_usec; /* microseconds */
};
```

### Git仓库登记

https://docs.qq.com/sheet/DWmx4R2tZdWFiYmNp?tab=BB08J2